UNIDAD 2 OPTATIVA

INTRODUCCIÓN AL PROMPT ENGINEERING

Índice

1. *Qué es el Prompt engineering* 2
2. *Componentes de un Prompt* 2
3. *Técnicas habituales* 3
4. *Aplicaciones del prompt engineering* 12
5. *Configuración del LLM* 12



1. Qué es el Prompt engineering

El **Prompt Engineering** (o ingeniería de instrucciones) es la práctica de diseñar, estructurar y refinar los textos de entrada (*prompts*) que se le dan a una inteligencia artificial generativa (como ChatGPT, Claude o Midjourney) para obtener las respuestas más precisas, relevantes y útiles posibles.

Como los modelos de lenguaje funcionan prediciendo las palabras más probables según el contexto proporcionado, la forma en que formulas una pregunta o instrucción cambia drásticamente el resultado.

Hablar “bien” a la máquina mejora la calidad de las respuestas y la eficiencia en las tareas, aunque esto no significa que se le deba hablar como a una persona, esto es una forma de “humanizar” la IA.

La ingeniería de prompt no solo se trata de diseñar y desarrollar prompts. Abarca una amplia gama de habilidades y técnicas útiles para interactuar y desarrollar con LLM (Large Language Model o Grandes Modelos de Lenguaje).

Nota: El significado de estas palabreas inglesas sería prompt=inmediato/a y prompts=indicaciones-instrucciones

2. Componentes de un Prompt

Para aplicar *prompt engineering* de forma efectiva, se suelen combinar varios de estos componentes:

1. **Rol / Persona:** Indicarle a la IA qué papel debe asumir.
    - *Ejemplo:* "Actúa como un experto en marketing digital, programador en java..."
2. **Tarea clara:** Definir la acción específica que debe realizar.
    - *Ejemplo:* "...redacta tres propuestas de asunto para un correo de ventas..."
3. **Contexto:** Dar información de fondo o detalles específicos para acotar la respuesta.
    - *Ejemplo:* "...para un software de contabilidad dirigido a pequeñas empresas."
4. **Formato de salida:** Especificar cómo quieres la respuesta, cómo debe estructurarla...
    - *Ejemplo:* "Presenta los resultados en una tabla con columnas para 'Título', 'Tono' y 'Público objetivo'."
5. **Restricciones:** Señalar qué evitar o qué límites respetar.
    - *Ejemplo:* "No uses clichés ni palabras como 'revolucionario'. Máximo 10 palabras por asunto.", menos de tantas líneas de código...

Buenas prácticas

- Claridad y precisión: Evitar ambigüedades en las instrucciones
- Concisión: Ser directo y evitar información innecesaria (por ejemplo, el inglés es un idioma más directo que el español).
- Iteración: Refinar Prompts basándose en las respuestas obtenidas anteriormente.
- Uso de ejemplos: Proporcionar ejemplos para guiar al modelo.



No es necesario usarlo todo en todas las consultas, cuando los prompts son sencillos no hace falta darle ejemplos o roles...

Puedes ver consejos generales para diseñar prompts en la Guía de Ingeniería de Prompts:

https://www.promptingguide.ai/

3. Técnicas habituales

- **Zero-Shot Prompting:** Pedirle a la IA que haga algo directamente sin darle ejemplos previos. Es la más básica y la más conocida.

Ejemplo: Resume el siguiente texto en una frase. Quizá lo ideal sería decirle "... frase lo más positiva posible, que use un ejemplo...".

- **Few-Shot Prompting:** Proporcionarle uno o varios ejemplos del formato o estilo deseado antes de pedirle el resultado final para guiar su respuesta.

Este es un ejemplo muy, muy básico para guiar o "entrenar" a la máquina. Podéis probarlo en ChatGPT.

Ejemplo:

Gran producto, 10 de 10: positivo

No funcionó muy bien: negativo

Super útil, vale la pena: positivo

¡No funciona!

Respuesta:

Negativo.

- **Chain-of-Thought o CoT (Cadena de pensamiento):** Instruir al modelo pidiéndole a la IA que "piense y explique su razonamiento paso a paso" antes de dar la respuesta final, lo cual **mejora drásticamente su precisión en tareas lógicas o matemáticas.**

Ejemplo clásico (los modelos algo antiguos solían fallar bastante en lógica y matemáticas en modo “normal”, ahora ya no, porque precisamente se les ha mejorado esta técnica de “pensar”):

Prompt: Tenía 23 caramelos. Le di 5 a mi hermano y compré el doble de los que me quedaban. ¿Cuántos caramelos tengo ahora? Pensemos paso a paso.

Respuesta de la IA:

1. Tenías 23 caramelos y le diste 5 a tu hermano. 23 - 5 = 18 caramelos restantes.
2. Te quedaron 18 caramelos. Luego compraste el doble de esa cantidad. El doble de 18 es 18 × 2 = 36 caramelos nuevos comprados.
3. Para saber el total, sumamos los caramelos que te quedaban más los que compraste: 18 + 36 = 54 caramelos.

Respuesta final: Ahora tienes 54 caramelos.

- **Self-Consistency (Autoconsciencia):** es una evolución directa de *Chain-of-Thought* (cadena de pensamiento). Fue introducida por investigadores de Google en 2022 y es súper útil para evitar que la IA te dé una respuesta equivocada por tomar un "camino lógico" defectuoso a la primera.

Consiste en, en lugar de pedirle a la IA que genere una sola respuesta paso a paso, solicitarle que genere múltiples respuestas o rutas de razonamiento independientes para el mismo problema y luego elija la respuesta más frecuente o consistente (por "votación de mayoría").

OJO: Si 5 caminos lógicos distintos llegan al mismo resultado, es extremadamente probable que la respuesta sea correcta. Si cada intento da algo distinto, la IA está "alucinando".

Si tenemos el siguiente código Java:

```
List<String> lista = new ArrayList < > (List.of("A", "B", "C"));
try {
   lista.add(1, "X");
   lista.remove(3);
   System.out.println(lista.get(3));
} catch (IndexOutOfBoundsException e) {
   System.out.println("Error de índice");
}
```

Ejemplo sencillo (mal):

"¿Cuál es la salida de este código Java con un ArrayList y un try-catch?"

Esto hace un solo intento; si se equivoca en la traza, te da una respuesta falsa.

Ejemplo (bien):

Analiza el siguiente código de Java. Para asegurarnos de que la respuesta sea correcta, realiza el seguimiento del código **3 veces de forma totalmente independiente**, como si fueras 3 programadores distintos haciendo una prueba de escritorio.

Estructura de respuesta:

- **Intento 1:** Traza paso a paso del estado de la lista y el bloque try-catch.
- **Intento 2:** Traza paso a paso evaluando los índices en cada operación.
- **Intento 3:** Traza paso a paso enfocada en las excepciones que puedan saltar.
- **Conclusión Final:** La respuesta que haya obtenido la mayoría de los intentos.

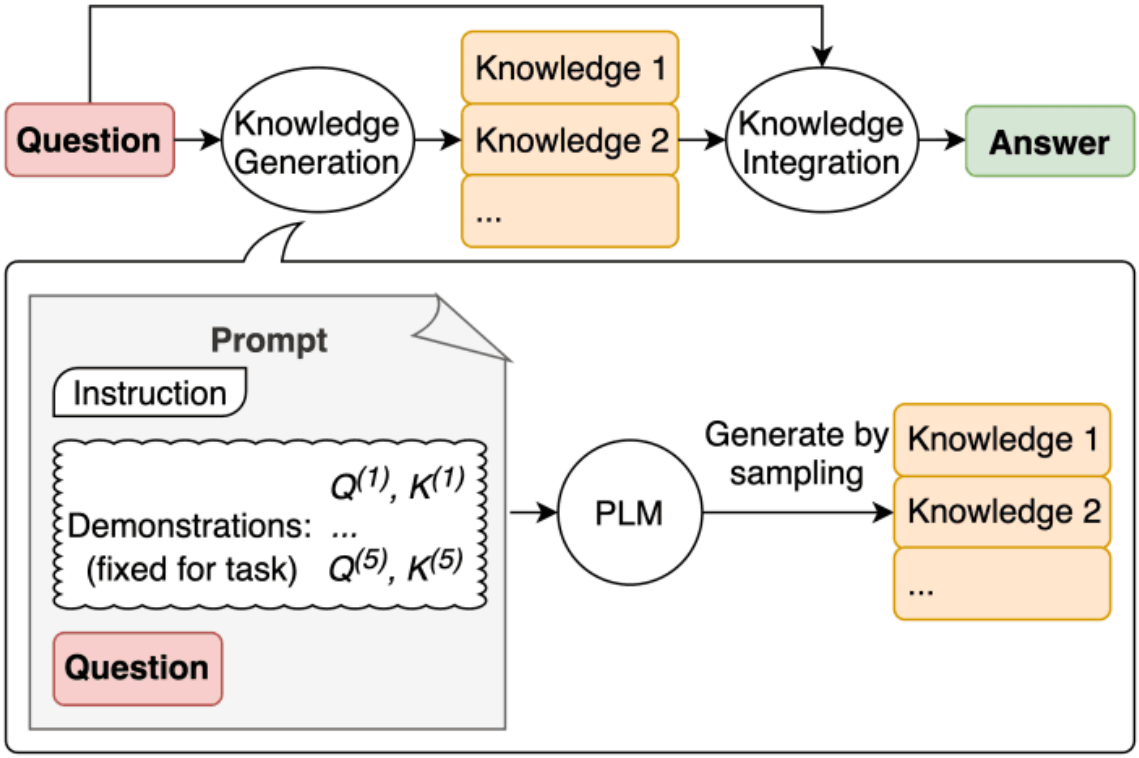
En programación, es buena idea usar esta técnica para pruebas de escritorio, para matemáticas y algoritmos (por ejemplo, conteo de elementos en colecciones complejas, cálculo de complejidad $O_{(n)}$, seguimiento de bucles anidados o comprobar si un flujo va a caer en un catch o no).



MÁS TÉCNICAS

- **Generated Knowledge Prompting (Prompt de conocimiento generado)**

Consiste en pedir al modelo que genere información relevante ANTES de responder, incorporando al input conocimiento e información previa para ayudar al modelo a hacer predicciones más precisas.



Ejemplo (mal y antiguo, pero para que se vea académicamente):

Parte del juego del golf es intentar obtener una mayor puntuación que tu oponente.

¿Sí o no?

Respuesta mal: Sí

Como la herramienta conoce deportes y normalmente, gana el que más puntúa gana algún LLM puede que alguna pueda llegar a dar una mala respuesta.

Por tanto, lo que se hace dentro del prompt, es dar entrada a modo de instrucción, pero justo después antes de pedir que se dé la respuesta se le sigue dando un conocimiento, repito, antes de pedir la respuesta.

Ejemplo:

Input: Las gafas siempre se empañan.

Conocimiento: La condensación se produce en los cristales de unas gafas cuando el vapor de agua de tu sudor, respiración y humedad ambiental se deposita en una superficie fría, se enfría y luego se convierte en pequeñas gotas de líquido, formando una película que se ve como niebla. Sus gafas estarán relativamente frías en comparación con su aliento, especialmente cuando el aire exterior está frío.

Pregunta final: ¿Qué medidas puedo tomar para evitar que mis gafas se empañen al pasar de un ambiente frío a uno cálido?

- **Prompt Chaining (encadenamiento de indicaciones)**

El **prompt chaining** (o encadenamiento de prompts) es una técnica de ingeniería de prompts que divide una tarea compleja en una secuencia de pasos más simples, donde el resultado de un prompt se convierte en la entrada del siguiente.

¿Cómo funciona?

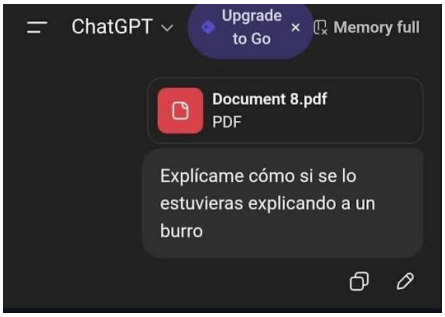
- **División de tareas:** En lugar de pedirle al modelo de lenguaje (LLM) que resuelva un problema grande de golpe, la tarea se desglosa en subtareas manejables.
- **Flujo secuencial:** La salida de la primera instrucción alimenta a la segunda, creando una cadena de montaje lógica.
- **Control de errores:** Si un paso falla, resulta más fácil identificar en qué punto de la cadena ocurrió el error para corregirlo de forma aislada.

Ventajas principales

- **Mayor precisión:** Reduce las alucinaciones y las respuestas mediocres de la IA.
- **Menor carga de contexto:** Cada llamada al modelo se concentra únicamente en un objetivo específico.
- **Trazabilidad:** Facilita auditar y optimizar cada etapa del proceso de manera independiente.

Casos de uso

Un caso de uso común de los modelos de lenguaje natural (LLM) consiste en responder preguntas sobre un documento de texto extenso. Resulta útil diseñar dos preguntas distintas: la primera se encarga de extraer las citas relevantes para responder una pregunta, y la segunda toma como entrada las citas y el documento original para responder la pregunta original. En otras palabras, se crean dos preguntas diferentes para realizar la tarea de responder una pregunta planteada en un documento.



Ejemplo:

Paso 1: Definir el objetivo principal

Prompt 1: "Describe el objetivo principal de una estrategia de marketing digital para una empresa que vende productos ecológicos."

Respuesta del modelo: "El objetivo principal es aumentar la visibilidad de la marca entre consumidores interesados en productos sostenibles y generar un incremento del 20% en ventas en los próximos 6 meses."

Paso 2: Identificar el público objetivo

Prompt 2: "Basándote en el objetivo principal definido, describe el público objetivo al que debe dirigirse la estrategia."

Respuesta del modelo: "El público objetivo son adultos de 25 a 45 años, con interés en temas ambientales, sostenibilidad y salud. Suelen utilizar redes sociales como Instagram y Facebook y prefieren marcas que muestren transparencia y compromiso ecológico."

Paso 3: Seleccionar los canales de comunicación

Prompt 3: "Sugiere los canales de comunicación más efectivos para llegar al público objetivo identificado."

Respuesta del modelo: "Los canales más efectivos son: Redes sociales: Instagram, Facebook y TikTok para contenido visual y campañas de impacto. Email marketing: Para enviar ofertas personalizadas y boletines informativos. Blog corporativo: Publicar contenido educativo sobre sostenibilidad y el uso de productos ecológicos."

Paso 4: Diseñar las acciones clave

Prompt 4: "Propón 3 acciones clave para implementar en los canales seleccionados, alineadas con el objetivo de aumentar las ventas y la visibilidad de la marca."

Respuesta del modelo: "Acciones clave: Crear campañas publicitarias en Instagram con influencers ecológicos. Ofrecer descuentos exclusivos a suscriptores del boletín a través de email marketing. Publicar una serie de artículos en el blog sobre los beneficios de los productos ecológicos."

Paso 5: Establecer métricas de evaluación

Prompt 5: "Sugiere métricas clave para evaluar el éxito de la estrategia implementada."

Respuesta del modelo: "Métricas clave: Incremento en el tráfico web (meta: +30% en 6 meses). Aumento de seguidores en redes sociales (meta: +10,000 seguidores en Instagram). Incremento en la tasa de conversión de ventas (meta: pasar del 2% al 4%)."

Por tanto, un esquema general a seguir para el orden de los pasos podría ser:

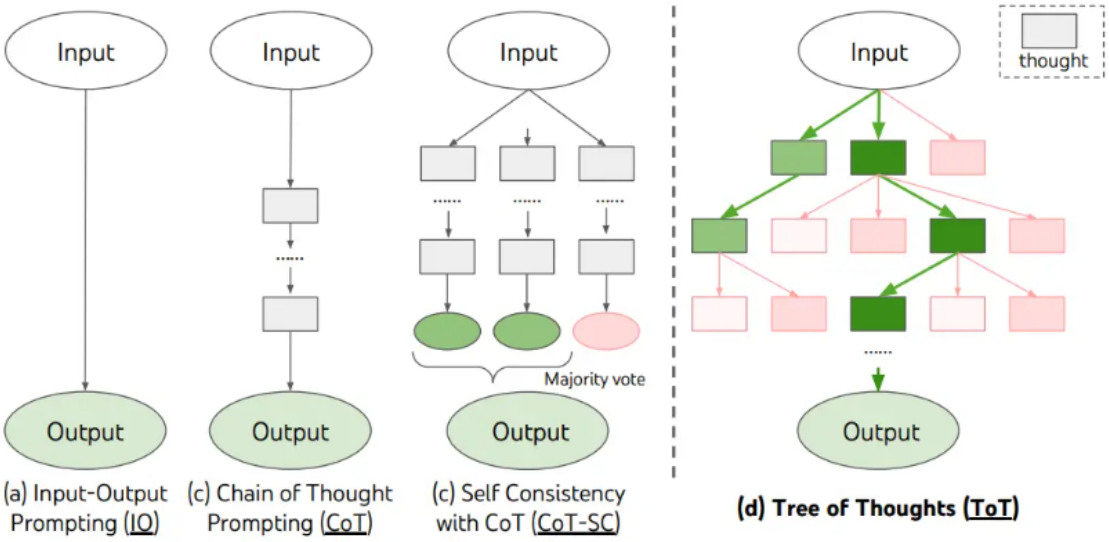


- **Tree of Thoughts- ToT (Árbol de pensamientos)**

Para tareas complejas que requieren exploración o planificación estratégica, las técnicas de indicaciones tradicionales o sencillas resultan insuficientes.

ToT mantiene un árbol de pensamientos, donde estos representan secuencias lingüísticas coherentes que sirven como pasos intermedios para resolver un problema. Este enfoque permite que un LM autoevalúe el progreso a través de los pensamientos intermedios realizados para resolver un problema mediante un proceso de razonamiento deliberado. La capacidad del LM para generar y evaluar pensamientos se combina con algoritmos de búsqueda (por ejemplo, búsqueda en amplitud y búsqueda en profundidad) para permitir la exploración sistemática de pensamientos con anticipación y retroceso.

El marco de trabajo se ilustra a continuación:



NOTA: Si quieres saber más: https://www.promptingguide.ai/techniques/tot

Las técnicas siguientes se irán estudiando más adelante cuando profundicemos de manera más adecuada en el uso avanzado.

- **Retrieval Augmented Generation**

Para tareas más complejas y que requieren un mayor conocimiento, es posible construir un sistema basado en modelos de lenguaje que acceda a fuentes de conocimiento externas para completarlas. Esto permite una mayor coherencia factual, mejora la fiabilidad de las respuestas generadas y ayuda a mitigar el problema de la "alucinación".

Los investigadores de Meta AI presentaron un método llamado Generación Aumentada de Recuperación (RAG) que estudiaremos más adelante al final del curso.

Para abordar tareas que requieren un alto nivel de conocimiento, RAG combina un componente de recuperación de información con un modelo generador de texto. RAG se puede ajustar con precisión y su conocimiento interno se puede modificar de manera eficiente, sin necesidad de reentrenar todo el modelo.

RAG toma una entrada y recupera un conjunto de documentos relevantes/de apoyo a partir de una fuente (por ejemplo, Wikipedia). Los documentos se concatenan como contexto con la entrada original y se envían al generador de texto, que produce el resultado final. Esto hace que RAG sea adaptable a situaciones donde los hechos pueden evolucionar con el tiempo. Esto es muy útil, ya que el conocimiento paramétrico de los modelos de lenguaje es estático. RAG permite que los modelos de lenguaje eviten el reentrenamiento, lo que posibilita **el acceso a la información más reciente** para generar resultados fiables mediante la generación basada en la recuperación.

- **Automatic Reasoning and Tool-use (ART) (Razonamiento Automático y uso de herramientas)**

La combinación de indicaciones y herramientas de CoT de forma intercalada ha demostrado ser un enfoque sólido y robusto para abordar muchas tareas con LLM. Estos enfoques suelen requerir la elaboración manual de demostraciones específicas para cada tarea y una intercalación cuidadosamente programada de la generación de modelos con el uso de herramientas.

El ART funciona de la siguiente manera:

- Ante una nueva tarea, selecciona demostraciones de razonamiento de varios pasos y uso de herramientas de una biblioteca de tareas.
- En el momento de la prueba, pausa la generación cada vez que se llaman herramientas externas e integra su salida antes de reanudar la generación.

ART fomenta que el modelo generalice a partir de demostraciones para descomponer una nueva tarea y utilizar herramientas en los lugares apropiados, de forma completamente nueva. Además, ART es extensible, ya que permite a los humanos corregir errores en los pasos de razonamiento o añadir nuevas herramientas simplemente actualizando las bibliotecas de tareas y herramientas.

- **Automatic Prompt Engineer (Ingeniería de avisos automáticos)**

Se propone el marco de trabajo Automatic Prompt Engineer (APE) para la generación y selección automática de instrucciones. El problema de la generación de instrucciones se plantea como síntesis de lenguaje natural y se aborda como un problema de optimización de caja negra, utilizando modelos lineales lógicos (LLM) para generar y buscar soluciones candidatas.

El primer paso consiste en utilizar un modelo de lenguaje extenso (como modelo de inferencia) al que se le proporcionan demostraciones de salida para generar posibles instrucciones para una tarea. Estas soluciones candidatas guiarán el procedimiento de búsqueda. Las instrucciones se ejecutan utilizando un modelo objetivo y, a continuación, se selecciona la instrucción más adecuada en función de las puntuaciones de evaluación calculadas.

- **Active-Prompt (Mensaje activo)**

Los métodos de cadena de pensamiento (CoT) se basan en un conjunto fijo de ejemplos anotados por humanos. El problema con esto es que los ejemplos podrían no ser los más efectivos para las diferentes tareas.

Recientemente se propuso un nuevo enfoque de indicaciones llamado Active-Prompt para adaptar los LLM a diferentes indicaciones de ejemplos específicos de la tarea (anotadas con razonamiento CoT diseñado por humanos).

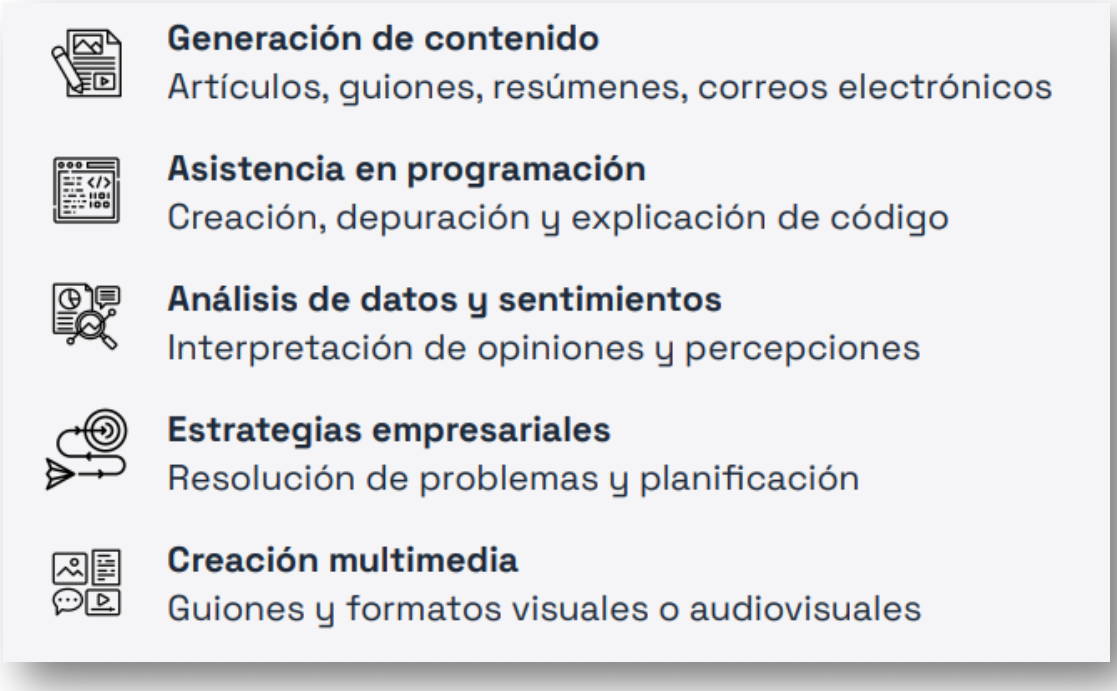
El primer paso consiste en consultar el modelo LLM con o sin algunos ejemplos de CoT. Se generan k posibles respuestas para un conjunto de preguntas de entrenamiento. Se calcula una métrica de incertidumbre

basada en las k respuestas (se utiliza el grado de desacuerdo). Las preguntas más inciertas se seleccionan para su anotación por parte de personas. Los nuevos ejemplos anotados se utilizan posteriormente para inferir cada pregunta.

NOTA: Como puedes ver, las técnicas más complejas tienen mucha matemática detrás y no es objetivo de este curso.

Puedes leer más sobre estas y otras técnicas en: https://www.promptingguide.ai/techniques

4. Aplicaciones del prompt engineering



Ejercicio: combina estos conocimientos creando tu propio GPTs o Gems.

5. Configuración del LLM

Aunque más adelante estudiaremos con más profundidad cómo configurar distintos LLM, cuando trabajas con prompts, interactúas con el LLM a través de una API o directamente. Puedes configurar algunos parámetros para obtener diferentes resultados para tus prompts. Estos pueden ser el top_p o la temperatura.

No se trata de lo bueno o malo que sea el resultado, sino de lo **predecible o aleatorio** que se permite que sea el modelo. La recomendación general es modificar uno de los dos, no ambos.

Top_p - Una técnica de muestreo con temperatura llamada muestreo de núcleo, puedes controlar la determinación del modelo al generar una respuesta. Si buscas respuestas exactas y factuales, mantén este valor bajo. Si buscas respuestas más diversas, aumenta el valor.

Temperature - En resumen, cuanto menor sea la temperatura, más deterministas serán los resultados en el sentido de que siempre se elige el siguiente token más probable. Aumentar la temperatura podría llevar a más aleatoriedad y fomentar resultados más diversos o creativos. Básicamente, estamos aumentando los pesos de los otros posibles tokens. En términos de aplicación, es posible que deseemos utilizar un valor de temperatura más bajo para tareas como preguntas y respuestas basadas en hechos para fomentar respuestas más concisas y factuales. Para la generación de poemas u otras tareas creativas, podría ser beneficioso aumentar el valor de la temperatura.

Normalmente, usado como siempre estamos sobre el 0.7, como por defecto, pero a menos que se esté experimentando o ideando, esta forma incluye riesgo de alucinaciones. Para prompts serios y estructurados, un uso de 0.2 o 0.3 tiene resultados más consistentes y controlables.

Una regla general podría ser:

Redacción de borradores o contenido estructurado 0.4–0.5

Codificación/depuración/técnico 0–0.2

Lluvia de ideas o creación de mundos 0.8–1.0

En la interfaz pública de ChatGPT, no existe un botón ni una configuración oficial para cambiar el parámetro de temperatura de forma directa.

Dónde y cómo se configura la temperatura

- **Versión web y aplicación móvil:** OpenAI no permite modificar la temperatura en el chat de usuario común. Escribir comandos como temperatura: 0.2 dentro de la conversación no cambia el parámetro técnico del modelo.
- **A través de la API:** Si desarrollas o usas herramientas mediante la OpenAI Playground, sí verás un control deslizante (slider) para ajustar la temperatura de 0 a 2.

Simular la temperatura con un *Prompt*

Puedes lograr el mismo efecto de control de creatividad cambiando la forma en la que redactas tus instrucciones (*prompts*):

- **Temperatura baja (0.0-0.2 / Modo Preciso):** Añade al inicio o final del prompt órdenes como: *"Actúa con máxima precisión, rigor técnico y literalidad. Sé directo, conciso, evita cualquier metáfora, adorno creativo o variación innecesaria. Elige siempre la opción más obvia y factual"*.

- **Temperatura media (0.4-0.7 / Modo Equilibrado):** Escribe instrucciones del tipo: *"Mantén un tono profesional pero natural. Ofrece explicaciones claras y fluidas, con un balance adecuado entre formalidad y variedad de vocabulario"*.
- **Temperatura alta (0.8-1.2 / Modo Creativo):** Utiliza peticiones como: *"Sé sumamente original, innovador y arriesgado. Utiliza metáforas inesperadas, puntos de vista poco convencionales y un lenguaje expresivo o poético"*.

También puedes usar etiquetas de control personalizadas dentro de tus notas o prompts recurrentes, escribiendo al final o en el rol del sistema algo como {Temperatura: 0.2} o {Temperatura: 1.4} para que la IA asuma esa directriz en el estilo de redacción.